

Performance Evaluation of Host Aware Shingled Magnetic Recording (HA-SMR)

Drives

內容摘要

這篇論文針對 **Host-Aware Shingled Magnetic Recording (HA-SMR)** 硬碟進行深入的效能評估，目的在於理解 HA-SMR 在實際系統中所展現的效能特性，以及其獨有的 **zoned block API**、**write pointer** 與 **media cache** 機制，會如何影響不同 I/O workload 的表現。相較於 drive-managed SMR (DM-SMR) 將所有複雜度隱藏在硬碟內部，HA-SMR 將部分內部狀態（例如 zone 資訊、write pointer 位置、zone 狀態）暴露給 host，理論上可讓系統端進行更精細的最佳化；然而，這也意味著效能行為高度依賴 host 的 I/O 使用方式。作者認為，若缺乏對 HA-SMR 效能特性的理解，這種「host-aware」的設計反而可能導致比傳統 HDD 更不可預測的效能退化。

為了系統性地分析這些問題，作者以 Seagate 8TB HA-SMR 樣品碟為實驗對象，搭配 libzbc 與 fio 工具，設計一系列 microbenchmark 來拆解 HA-SMR 的關鍵效能來源。評估重點不在於與 HDD 做單純的平均效能比較，而是聚焦於三個 HA-SMR 特有的效能瓶頸：**open zone resource 限制 (Open Zone Issue)**、**non-sequential write 分散於多個 zones 所導致的 blocking media cache cleaning (Non-Sequential Zone Issue)**，以及 **media cache cleaning efficiency 如何受 I/O request 數量、大小與寫入位置影響**。透過這些實驗，作者發現即使是順序寫入，只要同時操作的 open zones 超過建議上限，效能仍會因 metadata 同步成本而大幅下降；而在 non-sequential writes 的情境下，一旦 media cache 被迫進行 blocking cleaning，吞吐量甚至可能下降數個數量級，形成嚴重的效能斷崖。

除了合成 workload，作者亦將 36 條 Microsoft Research Cambridge 的企業級真實 I/O traces replay 在 HA-SMR 與傳統 HDD 上，以驗證前述觀察是否會在實務環境中出現。結果顯示，HA-SMR 在多數情況下的平均延遲與中位數延遲並不一定劣於 HDD，但在 media cache cleaning 觸發時，會產生極端的 tail latency，使得效能可預測性大幅降低。基於這些發現，作者進一步提出一個由 host 控制的間接緩衝機制 **H-Buffer**，將 HA-SMR 的資料路徑擴展為三種模式，嘗試透過 host 端重導向與清理策略，緩解 open zone 與 non-sequential zone 所帶來的效能問題，並展示其在特定情境下的潛在效益。

設計細節和模擬評估

1. HA-SMR 評估方法設計與實驗環境

I. 軟體部分：fio 微基準與 zone-aware 測試腳本

作者使用 **fio** 搭配 **libzbc**，設計一系列可控制 zone 行為的 I/O microbench，用以觀察 HA-SMR 在不同 open zone 與 non-sequential zone 條件下的 throughput 與 latency 變化。與傳統 block device 不同，測試腳本會同時記錄 drive 回報的 write pointer 位置與 non-sequential zone 數量，以將效能結果對應回 zone 狀態。作者特別關閉 write cache 與 read-ahead，避免 DRAM cache 掩蓋 media cache 與 cleaning 行為。

作者共設計多組 microbenchmarks，以下列出與效能關係最直接的幾項測試：

- **TEST 1：Open zone 數量對順序寫效能的影響**

以 bursty sequential write（含 idle gap）方式，對多個 zones 進行 round-robin 寫入，逐步增加同時 open 的 zone 數量，觀察 throughput 是否出現臨界點，以推得 HA-SMR 的 open zone resource 限制。

- **TEST 2：Open zone 數量對 non-sequential write 的影響**

使用相同 open zone 配置，但將寫入改為 non-sequential write，比較其效能變化，用以判斷 non-sequential write 是否同樣消耗 open zone metadata 資源。

- **TEST 3：Non-sequential zone 數量與 blocking cleaning 行為**

長時間執行 non-sequential write，刻意將寫入分散至大量 zones，觀察 throughput 隨時間變化，並記錄 blocking media cache cleaning 發生的時間與持續長度。

- **TEST 4：不同 non-sequential zone 數量下的 cleaning 代價**

比較 non-sequential writes 分散於較少 zones 與大量 zones 的情況，觀察每次 cleaning 所能回收的 media cache 空間與整體執行時間。

II. workload 參數控制與效能指標

在上述測試中，作者系統性地控制 I/O size（4KB、256KB、512KB）、寫入位置（靠近 zone start 或 zone end）、以及 request 數量，並量測以下指標：

- 平均與即時 throughput
- write completion time
- media cache cleaning 的啟動時機與持續時間
- non-sequential zone 數量的成長與回落

透過同時觀察效能指標與 zone 狀態，作者得以將效能斷崖直接對應到 HA-SMR 的結構限制，而非僅停留在現象描述。

2. Media cache cleaning 行為與真實工作負載評估

I. Media cache cleaning efficiency 的拆解測試

為進一步理解 cleaning 成本的來源，作者設計一組針對 cleaning 行為的細部實驗：

- **TEST 5：更新比例與寫入位置對 cleaning 的影響**
在 empty zone 與 full zone 中，分別控制更新比例與寫入位置，觀察 cleaning 時間的變化，用以推斷 fill data 與 read-modify-rewrite 的相對成本。
- **TEST 6：I/O request size 與 request 數量的影響**
在總寫入量固定的前提下，改變 I/O size 與 request 數量，觀察 cleaning 所需時間，藉此判斷 seek 與 mapping manipulation 是否為 cleaning 的主要瓶頸。
- **TEST 7：Zone-oriented reordering 對 cleaning 的改善效果**
將原本 interleaved 的 non-sequential writes 重新依 zone 分組後寫入，比較 write completion time 與 idle cleaning time，驗證 host 端 I/O 排列對 HA-SMR 效能的影響。

II. 真實世界工作負載（MSR traces）重播評估

作者進一步選用 **Microsoft Research Cambridge** 所釋出的企業級 I/O traces，將其 replay 在 HA-SMR 與傳統 HDD 上，比較平均 latency 與 percentile latency 的差異。分析中特別關注 cleaning 是否發生，以及其與 write request 數量、zone footprint 之間的關聯性。透過 percentile latency（P50、P90、P99）的比較，評估 HA-SMR 在實務情境下的 tail latency 行為。

III. H-Buffer 架構與案例分析

基於前面 microbenchmark 與 trace replay 的觀察，作者提出 **H-Buffer** 作為 host-controlled 的中介緩衝區，並在案例研究中設計簡單的 open-zone policy：當同時順序寫入的 streams 超過建議 open zone 上限時，將部分寫入導向 H-Buffer，再由 host 進行回寫。作者比較啟用與未啟用 H-Buffer 的執行時間，評估其在不同 I/O size 情境下的潛在效益。

結論

這篇論文透過一系列精心設計的 microbenchmarks 與真實世界工作負載重播，系統性地揭露了 Host-Aware SMR (HA-SMR) 硬碟在效能上的關鍵特性與潛在風險。作者指出，HA-SMR 雖然透過 zoned block API 將部分內部狀態暴露給 host，提供了理論上的最佳化空間，但其效能行為高度依賴 host 對 zone 與寫入模式的使用方式。實驗結果顯示，無論是順序寫或非順序寫，只要違反 open zone 數量與 non-sequential zone 數量的結構性限制，就可能引發嚴重的效能退化；特別是在 media cache 觸發 blocking cleaning 時，吞吐量可能下降數個數量級，並導致極端的 tail latency。進一步的 cleaning efficiency 分析也顯示，清理成本不僅與寫入資料量相關，更受到 I/O request 數量與寫入分散程度的支配，使得傳統、zone-unaware 的 legacy workload 在 HA-SMR 上存在顯著風險。基於這些觀察，作者提出 H-Buffer 作為一種由 host 主導的間接緩衝機制，嘗試透過重新分配資料路徑來緩解 open zone 與 non-sequential zone 所造成的效能斷崖。整體而言，本文的結論清楚指出 HA-SMR 並非可直接替換傳統 HDD 的裝置，而是一種要求 host 端具備工作負載整形與資料管理能力的儲存模型，其效能可預測性與實際效益高度取決於系統層級的設計選擇。