

Benchmarking a New Paradigm: Experimental Analysis and Characterization of a Real Processing-in-Memory System

P76134579 尤若琇

1. 內容摘要

本篇 paper 作者深入探討了 PIM 技術，特別是以 UPMEM 架構為主的實驗分析，其整合了 DRAM 處理單元(DPUs)，並通過實驗跟 benchmark 測試，對其性能、瓶頸都做了完整的評估。

UPMEM 架構的設計主要是想要解決現今一些受到限制的高負載任務(像是神經網路、database)在處理數據時所面臨到的數據移動瓶頸，其創新之處在於使用傳統的 2D DRAM 晶片結合 DPUs，克服了 3D 堆疊技術所造成的高成本跟散熱的問題，主要涵蓋了：

- 提出自定義的 benchmark 對整體性能評估
- 提出 PRIM 套件，涵蓋了來自不同領域的 workload
- 比較 UPMEM PIM 系統跟傳統 CPU/GPU 系統的表現差異

透過完整的實驗數據，也證明 UPMEM 真的可以有效減少數據移動的成本，在很多高負載工作也展現出其優勢。

2. 問題定義

數據移動是降低效能的主要原因，大部分記憶體高負載工作更需要頻繁在 CPU 跟記憶體之間傳送大量數據，但其所造成的高延遲跟功耗使得傳統架構已經無法滿足這樣的要求。

一些研究報告也指出，數據移動也造成總系統能耗的 40%~60%，傳統的解決方法，像是提升記憶體頻寬、增加 cache 大小，只能在有限程度上緩解這個問題，但並沒有解決根本問題，PIM 做為一個創新的計算架構也開始受到討論，其主要集中解決的問題在下列 3 點上：

- 在 DRAM 中加入計算功能減少數據移動
- 在不依賴高成本的 3D 堆疊技術的前提下實現 PIM
- 設計一種通用性強的計算架構，可以適應多種高負載工作

3. 方法機制的精神或想法說明

UPMEM 主要核心方法就是在記憶體晶片中加入 DPUs 使記憶體也有計算能力，從而讓計算可以更靠近數據(computation near data)，減少 CPU 跟記憶體之間的數據傳送。

- 核心要件：
 - DPUs：專門處理高負載工作，每個 DPU 都有並行處理的能力
 - ◆ MRAM：存放需要處理的數據
 - ◆ IRAM：存放執行代碼
 - ◆ WRAM：緩存空間
- 計算模式：Single Program Multiple Data (SPMD)
 - 分塊處理：將數據分塊後分配到不同 DPU 上處理，最大化 parallization。
 - explicit data management：管理數據傳輸

4. 重點進行

實驗主要通過多維度的測試跟分析，探討 UPMEM 的特性：

- Benchmark 結果
 - 算數吞吐量高，但對於浮點數的運算性能較低，因為 DPU 不支持硬體浮點運算，只能通過軟體模擬。
 - 頻寬利用的程度跟訪問的模式有很大的關係(如順序/隨機訪問)。
- PrIM 性能分析
 - UPMEM 系統的能耗明顯比 CPU 和 GPU 低，效率也相對而言來得更高。
- 瓶頸跟挑戰
 - DPU 之間溝通問題：DPU 目前無法直接溝通，還是需要 CPU 當中介點，導致性能下降。
 - 浮點數不支持：雖然可以使用軟體模擬但效率較低，在實際應用時效果不佳。

5. 優點

- 數據移動成本降低：透過在記憶體內部計算可以明顯減少數據在記憶體跟 CPU 之間的傳輸，降低延遲跟功耗。
- 成本可控：基於較成熟的 2D DRAM 技術，避免了 3D 技術的高成本跟功耗問題。
- 靈活性跟通用性：可以支持多種類型的負載，應用範圍廣，在高負載工作上也表現更良好。

6. 缺點

- 溝通瓶頸：DPU 之間缺乏直接溝通的機制。
- 浮點數運算效能：無法使用硬體計算浮點數，性能會比起整數運算低。
- 記憶體限制：每個 DPU 的 WRAM 只有 64KB，對大規模的數據處理效果有限。

7. 可延伸方向

- 改善通信架構：讓 DPU 之間彼此可以直接互相溝通，例如設立專用總線減少對 CPU 的依賴。
- 硬體升級：增加硬體對浮點數的計算增加效能，使其應用範圍可以更廣。