

Improving Phase Change Memory Performance with Data Content Aware Access

P76134579 尤著琇

1. 內容摘要

PCM 是一個新興的 non-volatile 記憶體技術，具有像 DRAM 一樣的低存取延遲，也有向 Flash 一樣高的容量，適合作為混合記憶體系統的一部份，可是 PAM 在寫入時，比起讀取會消耗更多延遲跟能量，性能也受到寫入數據的內容跟被覆蓋內容的比例影響，這是由於 PCM 在 set 跟 reset 時的延遲有差異，set 的寫入時間大於 reset 寫入時間，而 reset 的耗能比 set 高，這樣 asymmetry 的特性也讓 PCM 遇到效能提升的瓶頸。

本論文作者經過觀察 PCM 的寫入延遲以及 all-zeros 和 all-ones 的結果後，提出了 DATACON 的方法，通過去選擇 all-zeros 或 all-ones 寫入有效降低寫入延遲跟功耗，也在多種 workload 的實驗下實驗評估，結果顯示 DATACON 在改善延遲、性能提升、整體功耗上都有不俗的表現。

2. 問題定義

隨著現代計算系統對大數據分析、機器學習需求增加，存儲技術性能遇到很大的瓶頸，雖然 PCM 的 non-volatile 跟可擴展性在替代 DRAM 技術上具備很好的潛力，可是在寫入時的延遲比起 DRAM 更耗時也更耗能，這主要也是因為 set 跟 reset 的寫入不對稱性，set 的寫入時間比 reset 寫入時間多，而 reset 的耗能比 set 高。

此外 PCM 在高頻寫入時也容易發生 bank conflict，讓延遲問題更嚴重，所以該如何減少 PCM 的寫入延遲跟能耗也成為一個重要的挑戰。

3. 方法機制的精神或想法說明

DATACON 的設計主要基於以下核心思想，根據寫入數據的內容去選擇最適合的覆蓋位置(all-zeros 或 all-ones)，以最低的延遲跟能耗去完成 PCM 的寫入，主要會有以下三步驟：

- 評估覆蓋內容的潛在優勢：首先，DATACON 會去計算覆蓋 all-zeros 或 all-ones 的性能，並選擇一個最具性能優勢的覆蓋模式，例如：當 set 位

數所佔的比例低於 60%時，覆蓋 all-zeros 必較節能，反之覆蓋 all-ones 較高效。

- 重新定向寫入地址：DATACON 通過記憶體控制器將寫入地址重新定向至最佳覆蓋的 physical address，以便進行單向的 set 或 reset 的動作，減少延遲跟能耗，這個轉換過程會記錄在一個 Address Translation Table 中，以便後續再次訪問使用。
- 重新初始化未使用的記憶體位置：為了確保未來寫入時可以有效利用最佳覆蓋位置，DATACON 會定期去清除未使用到的記憶體區域，將其初始化成 all-zeros 或 all-ones，以便未來寫入時可以進行高校覆蓋。

4. 重點進行：

- Data Content-Aware Writes：根據寫入數據的特徵，像是 set 位數的比例去動態調整最佳覆蓋模式，利用這樣的方式去減少 PCM 的寫入延遲跟功耗。
- Partition-Level Spatial Locality (PLSL)：DATACON 會針對一些訪問頻率較高的區域去進行地址轉換，減少系統開銷並增強訪問效率。
- Adaptive Address 管理：建立一個動態的 Address Translation Table，定期對未使用的位置去進行 all-zeros 或 all-ones 重置，保證後續的性能優化。

5. 優點

- 顯著減少寫入延遲跟功耗：通過剛剛所說到的 Data Content-Aware Writes，可以讓 DATACON 有係降低寫入延遲跟功耗，提升整體系統的性能。
- 低硬體成本：DATACON 的實現僅需要少量額外的硬體資源，大約 9KB 即可支援 128GB 的 PCM 記憶體。
- 兼容性強：DATACON 可以跟其他減少 PCM 寫入次數的技術結合，進一步優化性能，而且在不同的應用場景下也都展現良好的適應性。

6. 缺點

- 額外的管理開銷：在維護 Address Translation Table 跟重新定向寫入會為系統帶來少量管理負擔，尤其在規模極大的記憶體空間，這樣的問題可能加劇。
- 複雜度高：需要記憶體控制器去將地址轉換，還有在進行內容分析時，都可能增加控制器的複雜度跟成本。
- 依賴分區區域性：DATACON 在有明顯分區時表現最佳，但如果是高隨機訪問時效率可能會受到限制。

7. 可延伸方向

- 跨技術擴展：探索 DATACON 在其他新興記憶體技術像是 STT-MRAM 和 ReRAM 中的適用性。
- 改進 Address Translation Table：針對不同的 workload，優化 Address Translation Table 的管理方式可以減少額外的延遲並進一步提升效能。
- 增加內容分析能力：通過更精確的內容識別技術，使得 DATACON 可以在更多樣化的場景下選擇最佳覆蓋方式，實現更高效的寫入。