

Design Tradeoffs for SSD Performance

P76134579 尤著琇

1. 內容摘要

以 NAND flash 為基礎的 SSD，提供有別於傳統 rotating disks 更多的功能：

- 更高的 bandwidth。
- 在隨機 I/O 上的性能表現更好。
- 節能。
- 無須移動部件(absence of moving part)，進而提供系統的可靠性。

儘管 SSD 的單位容量成本高於傳統使用的 rotating disks，但在實際應用上卻可以提供更好的速率跟效果，這也因此讓它的實用範圍越來越大，擴及到生活中的各種應用。

然而，因為其設計中的架構 tradeoffs 問題，導致這類的知識經常被 SSD 製造商視為專利技術，很難理解其具體架構，本文作者提出一系列的 NAND flash 存儲相關的設計 tradeoff，但目前只能猜測現有 SSD 的內部構造，因此作者使用 DiskSim 模擬器去模擬基於 NAND flash 的特性，也利用各種工具分析，如全規模 TPC-C 基準測試、一個 Exchange 伺服器的 workload 以及各種 standard file system 的 workload。

而在分析時，也發現以下 issue 與 SSD 的性能有關：

- Data placement：可以提供 load balancing，以及影響 wear-leveling。
- Parallelism：單個 flash 的 bandwidth 跟速率都不足以達到其最佳性能，需要去協調 memory 的元件，實現並行操作。
- Write ordering：小型、隨機的 NAND flash 寫入對設計者來說是一大挑戰。
- Workload management：SSD 的性能跟 workload 高度相關。

最後，該篇作者引入了一種增加效率的新 model，並提出一個 wear-leveling algorithm 去延長 SSD 的壽命。

2. 問題定義

- SSD 設計缺乏透明性：對於 SSD 實際構造的瞭解不充分導致我們很難深入了解 SSD。
- 不同 workload 對 SSD 性能跟壽命影響：論文提出如何設計 NAND flash 使其在不同 workload 下可以達到最佳效能。
- SSD 的 **wear-leveling** 問題和清理挑戰：設計一種能夠有效管理 SSD 壽命的 wear-leveling 算法保證在多種 workload 下也可以達到好的清理效率。
- 設計折衷影響：SSD 設計涉及到多種技術選擇，包含文中提到的 **large allocation pool**、**large page size**、**Overprovisioning**、**Ganging**、**Striping**，對這些設計去進行折衷分析以平衡整體性能、耐久性跟效率。

3. 方法機制的精神或想法說明

- 模擬驗證：通過 DiskSim 模擬器去模擬環境，接著用 TPC-C、IOzone、Exchange、Postmark 四種 workload 去評估不同的設計，該模擬器經過修改也可以模擬 Parallel element 的行為，並模擬不同設計對性能的影響。
- wear-leveling 的改善：論文提出一個改良的 wear-leveling 機制，採用傳統 greedy 策略最大化清理的效率，還引入 **rate limiting**、**cold data migration** 兩種技術，確保 SSD 在長時間運行後仍然可以有均衡的壽命分布，避免某些區塊遇到提早老化導致整塊 SSD 壽命結束的問題。
- **Random Early Discard** 和 **cleaning of worn-out blocks** 技術：為了避免單個區塊使用，SSD 加入以上技術，可以根據不同區塊的剩餘壽命去動態調整回收頻率，使 wear-leveling 的效果更好，提升 SSD 在高 workload 時的耐久性。
- striping 跟 ganging 技術的並行優化：**striping** 可以將數據分散到多個晶片上，實現並行操作；**ganging** 則可以同步多個區塊的讀寫操作提升寫入的性能，兩者都可以在維持成本的同時，提升 I/O 的 **throughput**。
- overprovisioned：本文也探討到了 overprovisioned 的設計在 SSD 中保留部分空間減少頻繁的 erase，可以降低 SSD 在高 workload 下的壓力。

5. 重點進行：

測試 tradeoffs 方面主要分為五個方向：

- Microbenchmarks：可以看出在沒有加入 cleaning 時，跟 Random read/write 差不多，但加入 **cleaning** 後，**Sequential write** 的效果會比 Random write 好
- Page Size, Striping, and Interleaving：Interleaving 可以有效提升性能，但前提是系統中必須有足夠的 **sequential request** 增加 **request queuing**，當請求不足效果會降低，而 Random read/write 效果不如 Sequential read/write 效果明顯。
- Gang Performance：當使用 Shared-Bus Gang 沒有明顯的 load balancing 問題；**Shared-Control Gang** 在 **asynchronous** 跟 **synchronous** 模式下，asynchronous 會更好，因為 synchronous 會限制操作導致性能降低。
- **Copy-back vs. Inter-plane Transfer**：使用 **Copy-back** 清理時效率會高於 inter-plane 來的好，在 TPC-C 的 Random read/write 的 workload 中也可以減少大約 40% 的 cleaning cost，而在 IOzone 跟 Postmark 的 Sequential read/write 展現了近乎完美的效率。
- **Cleaning Thresholds**：SSD 需要設置一個最小的 free block 用作突發狀況使用，但當這個區塊閾值增加，會使得 SSD 雖然有足夠空間應對突發 request，但更早觸發清理也會導致增加清理頻率，延遲也會因此產生。

6. 優點

整篇 paper 在背景知識的介紹非常充足，包含了 wear-leveling、random/sequential read/write、整個 SSD 的架構等，很多內容跟老師上課提到的部

分也有重疊，關於模擬環境、測試工作的介紹也介紹的非常簡單明瞭，讓我耳目一新，在最後作者也非常仔細地將各種理論與其所搭配的實驗數據做出，更加佐證了他的想法，我認為結果很詳盡。

7. 缺點

論文的許多結論都來自 DiskSim 模擬器的測試結果，但我認為無法完整反映所有硬體實際的行為，實際運行的時候也會受到各種環境、溫度、老化程度等不可控的因素影響，感覺可以考慮更多變因進去，想必也可以讓結果更貼近生活。

再者，wear-leveling 的影響沒有充分的量化，像是 cold data 遷移也可能會導致 I/O 延遲增加，這樣的性能損失可否接受？感覺可以深入探討。

8. 可延伸方向

雖然作者提供完整模擬結果，但實際在硬體上的效果如何？是否會遇到其他挑戰？我認為也是未來可以實際實驗的方向。

效能優化上，我認為未來可以研究如何改進 SSD 來降低功耗，探索不同 workload 下動態的調整 striping 跟 ganging 的技術，透過降低功耗的方式減少更多成本，SSD 的應用早已滲透到許多領域，包含自駕車、物聯網、大數據分析，這些應用需求不斷地增加，提高各種性能獲近一步減少功耗相信也會對實際應用上提供巨大幫助。