

WiscKey: Separating Keys from Values in SSD-Conscious Storage

P76134579 尤著琇

1. 內容摘要

這篇 paper 的作者提出一種叫做 WiscKey 的儲存系統，基於 LSM-Tree、專門為 SSD 設計，通過將 key 跟 value 分離的方式去減少 I/O，而 WiscKey 的設計優化了 SSD 各項性能，並且有效減少 Read 跟 Write Amplification，可以提升性能跟 SSD 的壽命。

Paper 中主要提到的優化包含以下 4 點：

- Key 跟 value 分離：將 key 存在 LSM-Tree 中，value 則存放在獨立的 vLog。
- Parallel Range Query：利用 SSD 內部並行的特性去解決可能存在的 random I/O 開銷。
- Lightweight GC：設計線上 GC 的機制可以高校釋放無效值占用的空間。
- 崩潰一致性：透過 SSD 內部系統的特性實現具有可靠性的崩潰之後再恢復。

而在多種 workload 下，其讀寫效率遠遠超過 LevelDB 跟 RocksDB。

2. 問題定義

傳統 LSM-Tree 的 key-value 系統在面對 SSD（像是 LevelDB 和 RocksDB）

存在以下問題：

- I/O 擴增：因為 LSM-Tree 的壓縮跟排序的機制，造成寫入會放大 50 倍以上，讀取放大也很大，就會使 SSD 的壽命縮短、性能也嚴重下降。
- 隨機存取跟順序存取差異：在 SSD 上雖然隨機存取跟順序存取的性能差異已經不像傳統 HDD 那麼明顯，但在 SSD 上設計的 LSM-Tree 仍然用 HDD 的優化方式設計，沒辦法充分去利用 SSD 的性能。
- 崩潰恢復挑戰：LSM-Tree 的架構得在系統崩潰後的恢復成本很高。
- GC 效率低：現有的 GC 方式對於整體系統的負擔仍然很大。

3. 方法機制的精神或想法說明

WiscKey 的主要設計是透過將 key 跟 value 分離，去降低 I/O 並提高 SSD 效能：

- Key 跟 value 分離：將 key 存在 LSM-Tree 中去做 key 的排序跟快速 search；而 value 則存放在獨立的 vLog 避免壓縮時可能會對 value 進行不必要的移動。
- Parallel Range Query：利用 SSD 隨機讀取的並行特性預先讀取並緩存 value 的資料，避免頻繁去調用隨機存取的 data。
- GC 機制：GC 進行的時候僅針對無效值占用到的空間去處理，並用線上、漸進的方式，去減少對正常操作的影響。
- 崩潰一致性：會利用其他文件系統去確保崩潰後的 vLog 的一致性，透過將 vLog 跟 LSM-Tree 結合，崩潰後可以快速比對恢復數值。

4. 重點進行

- 數據布局：首先將 key 跟 value 分離，key 存在 LSM-Tree 中，value 的地址跟大小做數據存儲。
- Parallel Range Query 跟 GC
 - 透過多條 thread 去並行預取資料，實現高效的範圍查詢
 - 頭尾都設計 pointer 去逐步整理 vLog 的有效值跟無效值，減少整體資源的浪費。
- 性能評估：利用 microbenchmark 和 YCSB 跟 LevelDB 和 RocksDB 進行效能比較，包含像是讀寫延遲、Parallel Range Query 效率跟崩潰後恢復時間等。

5. 優點

- 顯著減少 Write Amplification：透過將 key 跟 value 分離管理減少壓縮過程中移動大量 value，可以減少寫入放大並延長壽命。
- 提升查詢性能：LSM-Tree 縮小後，查詢找到的概率提高，隨機查詢的延遲更低。
- GC 效率高：採用輕量 GC 的機制可以有效減少工作負載。
- 優化 Parallel Range Query：並行去讀取可以加速 Range Query，充分利用 SSD 的並行性能。

6. 缺點

- Range Query 的隨機性影響：對於小型的 key-value，Range Query 可能受到 SSD 隨機存取的瓶頸限制。

- 依賴硬體設計：設計會依賴 SSD 內部的並行性，對於性能較低的 SSD 可能效果不如高端硬體來的快。

7. 可延伸方向

- Range Query 優化：引入排序重組的技術可以優化 Range Query 小值的性能，縮小跟 LevelDB 的差異。
- 與 distributed system 的適配度：探索該如何將 WiscKey 應用在 distributed system 去平衡負載跟容錯性設計。
- 硬體適配性改進：進一步去優化對不同類型 SSD 的支持，針對較低端的 SSD 去設計更合適的 GC 跟查詢策略。